

RAPPORT DE PROJET

Modèle de Scoring

Prédire le risque de défaut de paiement à partir des données de demandes de prêt

Auteur : AKOTA Yao Jerome

Destinataire : BanqueOuest Africaine de Developpement (BOAD)

Carde : Projet Data Science et Machine learning

Résumé exécutif

Ce rapport présente le travail réalisé autour d'un modèle de scoring crédit destiné à évaluer, au moment de la demande de prêt, la probabilité qu'un emprunteur ne rembourse pas. La question est centrale pour une institution comme la Banque Ouest Africaine de Développement (BOAD), dont les engagements financent des projets de développement dans les huit pays de l'UEMOA : un mauvais crédit, ce n'est pas seulement une perte sèche, c'est aussi un projet qui ne se fera pas.

Faute de disposer d'un jeu de données réelles, confidentielles, nous avons construit un échantillon synthétique de 1 000 demandes de prêt calqué sur les variables habituelles du scoring (revenu, montant, durée, taux, score d'historique, ratio d'endettement, garanties, secteur). Deux modèles ont ensuite été entraînés et comparés sur un split 80/20 stratifié : une régression logistique et un Random Forest.

Le résultat principal tient en une ligne : **les deux modèles atteignent une accuracy de 91,5 %, mais la régression logistique surprend par son AUC de 0,972, légèrement supérieure à celle du Random Forest (0,959)**. C'est donc elle que nous recommandons comme outil principal, parce qu'elle est à la fois plus performante en discrimination et nettement plus interprétable pour les équipes risque.

Côté variables, le ratio d'endettement domine très largement l'importance du Random Forest (41 % de la réduction d'impureté), devant la durée du prêt, le revenu et le montant. Le score d'historique de crédit, souvent présenté comme le facteur n°1 dans la littérature, n'arrive qu'en cinquième position dans notre jeu synthétique un point à creuser avec des données réelles.

1. Contexte et problématique

1.1 Pourquoi s'intéresser au scoring crédit à la BOAD

La BOAD finance des projets de développement dans huit pays de l'UEMOA : Bénin, Burkina Faso, Côte d'Ivoire, Guinée-Bissau, Mali, Niger, Sénégal et Togo. Dans cet environnement, le risque de crédit n'est pas un détail comptable : c'est une variable qui conditionne la capacité de la banque à honorer ses engagements stratégiques. Quand un prêt part en défaut, ce ne sont pas seulement des intérêts qui manquent ce sont des écoles, des routes, des installations agricoles qui ne verront pas le jour, ou plus tard.

Le scoring crédit désigne l'ensemble des techniques statistiques qui permettent d'attribuer à chaque emprunteur une note de risque, c'est-à-dire une probabilité de défaut. L'idée n'est pas de remplacer le jugement humain des analystes de crédit, mais de leur fournir un signal objectif, reproductible, et calibré sur l'historique. C'est dans cette optique que ce projet a été monté : construire un premier prototype fonctionnel, sur données synthétiques, pour évaluer la pertinence de l'approche avant d'investir dans l'intégration de données réelles.

1.2 La question de départ

La question est volontairement simple : au moment où un dossier de demande de prêt arrive, peut-on à partir des informations disponibles dans le formulaire estimer la probabilité que cet emprunteur fasse défaut ? Si oui, avec quelle fiabilité, et avec quelles variables ?

Il s'agit d'un problème de classification binaire : la variable cible vaut 1 si l'emprunteur fait défaut (incident de paiement caractérisé), 0 sinon. Nous avons choisi de comparer deux familles de modèles très différentes : la régression logistique, parce qu'elle est lisible et qu'un coefficient peut s'expliquer à un comité de crédit ; et le Random Forest, parce qu'il capte les relations non linéaires et les interactions entre variables sans avoir à les spécifier à la main.

2. Données et méthodologie

2.1 Un jeu de données synthétique, mais pas arbitraire

Les données de crédit bancaire sont confidentielles. Plutôt que d'attendre un accord d'anonymisation qui aurait pris des mois, nous avons généré un jeu de données synthétique de 1 000 demandes de prêt. L'objectif n'était pas de reproduire fidèlement le portefeuille de la BOAD, mais de disposer d'un terrain d'expérimentation réaliste, avec les bonnes variables et des relations plausibles entre elles.

Douze variables ont été retenues, regroupées en trois familles. Les variables sociodémographiques (âge, situation familiale, nombre de personnes à charge) décrivent l'emprunteur ; les variables financières (revenu mensuel, montant du prêt, durée, taux d'intérêt, ratio d'endettement, score d'historique de crédit, nombre d'emprunts antérieurs) décrivent le dossier ; les variables catégorielles (secteur d'activité, présence d'une garantie) apportent le contexte. Le ratio d'endettement a été calculé comme le rapport entre le montant du prêt et le produit $\text{revenu} \times \text{durée}$, ce qui donne une approximation de la charge de remboursement.

La variable cible « défaut » a été construite à partir d'un logit semi-réaliste : un score d'historique bas augmente le risque, un ratio d'endettement élevé augmente le risque, l'absence de garantie augmente le risque, et un revenu élevé le diminue. Du bruit aléatoire a été ajouté pour éviter que la cible ne soit parfaitement déterministe. Le seuil a ensuite été ajusté pour obtenir environ 25 % de défauts, ce qui correspond à un ordre de grandeur observé sur certains portefeuilles de microfinance en zone UEMOA.

2.2 Méthodologie : un pipeline CRISP-DM court

Le travail suit une démarche inspirée de CRISP-DM, mais réduite à l'essentiel : compréhension du métier, compréhension des données, préparation, modélisation, évaluation, recommandations. Le découpage train/test est de 80/20, stratifié sur la cible pour conserver la proportion de défauts dans les deux sous-ensembles (25 % dans le train comme dans le test).

Trois choix méthodologiques méritent d'être signalés. Premièrement, le StandardScaler a été fit uniquement sur l'ensemble d'entraînement, puis appliqué au test pour éviter la fuite de données. Deuxièmement, l'encodage one-hot des variables catégorielles utilise `drop_first=True` afin d'éviter la colinéarité parfaite, qui perturbe l'estimation des coefficients de la régression logistique.

Troisièmement, les colonnes one-hot (0/1) n'ont pas été standardisées, seulement les variables numériques continues : standardiser des indicatrices n'apporte rien et complique l'interprétation.

Nous n'avons pas mis en place de validation croisée k-folds, ni de recherche d'hyperparamètres par GridSearch. C'est une limite assumée de cette première version : sur un échantillon de 1 000 lignes, un seul split suffit à donner une tendance, mais une validation plus robuste sera nécessaire avant tout déploiement.

3. Ce que disent les données avant la modélisation

3.1 Un quart des demandes part en défaut

La toute première chose à regarder, c'est l'équilibre des classes. Sur 1 000 demandes, 250 (25 %) sont étiquetées en défaut et 750 (75 %) en non-défaut. Ce n'est pas un déséquilibre extrême on n'est pas dans le cas classique de la détection de fraude à 0,1 % mais c'est suffisamment marqué pour qu'une accuracy naive de 75 % (tout prédire en non-défaut) constitue un faux-ami. Nous avons donc systématiquement regardé le rappel sur la classe 1, et pas seulement l'accuracy globale.




Figure 1 Distribution de la variable cible : 25 % de défauts, 75 % de bons remboursements.

3.2 Les profils des mauvais payeurs se dessinent déjà

Avant même d'entraîner un modèle, les boxplots racontent une histoire claire. Les emprunteurs en défaut ont, en médiane, un revenu mensuel plus faible que les bons payeurs, un montant de prêt légèrement plus élevé, un score d'historique de crédit plus bas, et surtout un ratio d'endettement nettement plus élevé. C'est sur ce dernier point que l'écart est le plus frappant : la médiane du ratio d'endettement chez les défaillants se situe au-dessus du troisième quartile des non-défaillants.




Figure 2 Boxplots des variables numériques selon le statut de défaut. L'écart le plus marqué porte sur le ratio d'endettement.

Les histogrammes confirment par ailleurs que les variables financières sont asymétriques : le revenu et le montant du prêt ont une queue à droite, ce qui est attendu (quelques gros dossiers tirent la moyenne vers le haut). Aucune transformation log n'a été appliquée à ce stade, mais ce serait une piste sérieuse pour améliorer encore le modèle, en particulier pour la régression logistique.

3.3 Le secteur d'activité et la garantie jouent, mais moins qu'attendu

Quand on croise le taux de défaut avec les variables catégorielles, on voit que l'absence de garantie augmente sensiblement la probabilité de défaut, et que certains secteurs (agriculture, BTP) présentent des taux plus élevés que les services. Cela dit, les écarts restent modérés et le nombre d'observations par catégorie limite la portée statistique de ces comparaisons. Ce sont des signaux à surveiller, pas des conclusions définitives.




Figure 3 Taux de défaut par variable catégorielle. L'absence de garantie ressort comme le signal le plus net.

3.4 Pas de multicolinéarité préoccupante

La matrice de corrélation montre que les variables numériques ne sont pas fortement corrélées entre elles, à l'exception attendue du lien entre montant du prêt et durée (les gros prêts durent plus longtemps) et du lien mécanique entre ratio d'endettement et ses composantes. Aucune corrélation supérieure à 0,8 n'a été détectée entre variables explicatives distinctes, ce qui permet de les conserver toutes sans risquer une instabilité numérique importante côté régression logistique.




Figure 4 Matrice de corrélation de Pearson des variables numériques. Pas de multicolinéarité préoccupante.

4. Modélisation et résultats

4.1 Régression logistique : simple, lisible, et efficace

La régression logistique a été entraînée avec `max_iter=1000` et `random_state=42`, sans pénalisation spécifique. Sur l'ensemble de test (200 observations), elle obtient une accuracy de 91,5 %. Plus important : elle ne se contente pas d'une accuracy globale flatteuse. Sur les 50 emprunteurs réellement en défaut, elle en identifie correctement 38 (rappel de 76 %), et ne produit que 5 faux positifs sur les 150 bons payeurs. Pour un premier modèle, c'est encourageant.




Figure 5 Matrice de confusion, régression logistique. Vrais négatifs : 145. Faux positifs : 5. Faux négatifs : 12. Vrais positifs : 38.

La courbe ROC illustre la capacité de discrimination du modèle : l'aire sous la courbe atteint 0,972, ce qui est très élevé. Concrètement, cela signifie que si l'on prend un pair constitué d'un emprunteur en défaut et d'un emprunteur sans défaut, le modèle attribuera une probabilité de défaut plus élevée au premier dans 97 % des cas. Ce taux de classement est bien supérieur à ce qu'on attend d'un scoring de production sur données synthétiques ce qui s'explique en partie par la nature contrôlée du logit utilisé pour générer la cible.




Figure 6 Courbe ROC, régression logistique. AUC = 0,972.

4.2 Random Forest : un peu plus de rappel, un peu moins d'AUC

Le Random Forest a été configuré avec 100 arbres et une profondeur maximale de 10 pour limiter le surapprentissage. Ses performances sont très proches de la régression logistique en accuracy (91,5 % également) et en F1 (0,821 contre 0,817). Il fait légèrement mieux en rappel (78 % contre 76 %, soit un défaillant de plus détecté), mais moins bien en AUC (0,959 contre 0,972) et en précision (0,867 contre 0,884).




Figure 7 Matrice de confusion, Random Forest. Vrais négatifs : 144. Faux positifs : 6. Faux négatifs : 11. Vrais positifs : 39.

L'importance des variables calculée par le Random Forest confirme ce que l'analyse exploratoire avait laissé entrevoir, avec une hiérarchie nette. Le ratio d'endettement domine très largement, avec 41 % de l'importance totale. Viennent ensuite, dans l'ordre, la durée du prêt (12 %), le revenu mensuel (12 %), le montant du prêt (11 %), et enfin le score d'historique de crédit (7 %). Les variables catégorielles one-hot encodées (situation familiale, secteur, garantie) pèsent chacune moins de 5 %.




Figure 8 — Importance des variables, Random Forest. Le ratio d'endettement capte 41 % de la réduction d'impureté.

4.3 Comparaison côte à côte

Le tableau ci-dessous résume les métriques des deux modèles sur l'ensemble de test. Les chiffres parlent d'eux-mêmes : sur ce jeu de données, la régression logistique n'a rien à envier au Random Forest, et le devance même sur deux dimensions clés (AUC et précision).

Métrique	Régression Logistique	Random Forest
Accuracy	0,915	0,915
Précision (classe 1)	0,884	0,867
Rappel (classe 1)	0,760	0,780
F1-Score (classe 1)	0,817	0,821
AUC-ROC	0,972	0,959
Vrais positifs	38 / 50	39 / 50
Faux négatifs	12	11

Tableau 1 Comparaison des performances des deux modèles sur l'ensemble de test (200 observations).




Figure 9 Superposition des courbes ROC des deux modèles. La courbe de la régression logistique est légèrement au-dessus sur la quasi-totalité des seuils.

4.4 Lecture des résultats

Comment expliquer qu'une régression logistique, modèle linéaire supposé « simpliste », batte un Random Forest sur ce jeu de données ? La réponse tient à la manière dont la variable cible a été construite. Le logit qui génère le défaut est une combinaison linéaire de variables (score historique, ratio d'endettement, garantie, revenu), avec un terme $\log_{10}$ sur le ratio d'endettement. Or, une régression logistique est précisément conçue pour apprendre ce type de relation linéaire dans le logit. Le Random Forest, lui, doit approximer cette structure par des seuils successifs, ce qu'il fait très bien mais au prix d'une légère perte en discrimination pure.

Sur des données réelles, où les relations sont plus bruitées, plus interagites et moins linéaires, l'écart pourrait s'inverser. C'est pour cette raison que nous recommandons de conserver les deux modèles dans le pipeline et de les réévaluer dès que des données réelles seront disponibles.

5. Recommandations pour la BOAD

Les recommandations qui suivent découlent directement des résultats obtenus sur le jeu de données synthétique. Elles sont volontairement opérationnelles : chacune peut être mise en œuvre dans un délai raisonnable, et chacune a un porteur naturel au sein de la BOAD.

5.1 Adopter la régression logistique comme modèle principal

C'est la recommandation centrale de ce rapport. La régression logistique affiche la meilleure AUC (0,972) et la meilleure précision (0,884), tout en offrant une interprétabilité directe : chaque coefficient indique l'effet marginal d'une variable sur le log-odds de défaut. Cela signifie qu'un

analyste de crédit peut lire le modèle, l'expliquer à un comité, et le challenger si besoin. Le Random Forest sera conservé comme modèle secondaire, à titre de contrepoint et de vérification.

5.2 Surveiller le ratio d'endettement en priorité

Le Random Forest identifie le ratio d'endettement comme la variable n°1, très loin devant les autres (41 % de l'importance). La BOAD a donc tout intérêt à fixer un seuil maximum d'endettement au-delà duquel un dossier est automatiquement signalé comme à risque. Une valeur courante dans la pratique bancaire est de 33 à 40 % du revenu mensuel ; à affiner avec les données du portefeuille réel.

5.3 Exiger une garantie pour les prêts à risque élevé

L'absence de garantie ressort comme un facteur de risque significatif, tant dans l'analyse exploratoire que dans les modèles. Pour les dossiers situés dans le tercile supérieur du ratio d'endettement, ou au-dessus d'un certain seuil de probabilité prédite, l'exigence systématique d'une garantie (hypothèque, caution, nantissement) constituerait un filet de sécurité utile.

5.4 Construire une base d'historique de crédit régionale

Le score d'historique de crédit pèse moins que prévu dans notre modèle (7 % seulement), mais c'est très probablement un artefact de notre génération synthétique. Dans la réalité, l'historique de remboursement est l'un des prédicteurs les plus puissants du défaut, c'est le cas dans quasiment toutes les études publiées. La BOAD, en coopération avec les banques centrales des pays de l'UEMOA et avec la BCEAO, aurait tout à gagner à promouvoir une base d'historique de crédit partagée, sur le modèle des centrales de risque.

5.5 Mettre en place un suivi post-octroi

Un score n'est pas une décision figée. Une fois le prêt accordé, la probabilité de défaut évolue avec la conjoncture, le comportement de paiement de l'emprunteur, et l'apparition de nouveaux incidents. Nous recommandons de mettre en place un suivi trimestriel des dossiers classés en risque moyen ou élevé, avec des alertes précoces en cas de premier incident de paiement.

6. Limites de l'étude

Ce travail doit être lu avec ses limites en tête. Trois d'entre elles méritent d'être explicitées sans détour.

Première limite, la plus évidente : les données sont synthétiques. Aussi réaliste que nous ayons cherché à être dans le choix des variables et dans la construction du logit, nous n'avons pas la prétention de reproduire la complexité du portefeuille réel de la BOAD. Les relations apprises par les modèles reflètent nos hypothèses de génération, pas la vérité du terrain. Une validation sur données réelles, même anonymisées et réduites à quelques milliers de lignes, est absolument indispensable avant tout déploiement.

Deuxième limite : l'absence de validation croisée. Nous nous sommes contentés d'un split 80/20 unique, avec une graine fixée. Sur 1 000 observations, l'intervalle de confiance d'une accuracy de 91,5 % est de l'ordre de ± 2 points. Une validation croisée à 5 plis stratifiée permettrait de resserrer cette incertitude et de s'assurer que les écarts entre les deux modèles sont robustes.

Troisième limite : aucun traitement spécifique du déséquilibre des classes. Avec 25 % de défauts, le déséquilibre est modéré et n'a pas nécessité de sur-échantillonnage (SMOTE) ou de pondération. Mais si le taux de défaut réel est plus faible (5 à 10 %, ce qui est plus courant en crédit bancaire classique), il faudra impérativement recourir à ces techniques, sans quoi le rappel sur la classe 1 s'effondrera.

7. Conclusion

Ce projet démontre la faisabilité d'un système de scoring crédit basé sur le machine learning dans le contexte de la BOAD. Sur un jeu de données synthétique de 1 000 demandes de prêt, la régression logistique atteint une AUC de 0,972 et une accuracy de 91,5 %, ce qui confirme que la structure des variables choisies (revenu, montant, ratio d'endettement, score d'historique, garantie) porte effectivement un signal prédictif exploitable.

Le ratio d'endettement ressort comme le facteur de risque n°1, loin devant les autres variables. Ce n'est pas une surprise, mais la confirmation quantitative d'une intuition que les analystes de crédit partagent depuis longtemps. Là où le scoring apporte une valeur ajoutée, c'est en objectivant cette intuition et en la combinant avec les autres variables pour produire une probabilité unique, comparable entre dossiers.

Les prochaines étapes sont claires. Il faudra d'abord reproduire ce pipeline sur des données réelles, même anonymisées, pour confirmer ou infirmer les résultats obtenus ici. Il faudra ensuite enrichir le feature engineering (transformation log des variables asymétriques, interactions, variables temporelles) et tester des modèles plus avancés (Gradient Boosting, XGBoost). Enfin, il faudra intégrer le modèle retenu dans le système d'information de la BOAD, avec un tableau de bord destiné aux analystes de crédit et un suivi continu de la dérive du modèle dans le temps.

Ce rapport est une première brique. Il montre que la démarche est viable, que les modèles tiennent leurs promesses sur un terrain contrôlé, et que les recommandations qui en découlent sont opérationnelles.